




Trabajo Práctico 3: Clasificación de Especies de Aves Indias mediante Redes Neuronales Convolucionales

Albornoz, Silvia Melisa - Armas, Mauro Nahuel - Bazán, Agustina -
Berronodo, Milagros del Valle

*Cátedra de Inteligencia Artificial
Ingeniería en Sistemas de Información*

Abstract

El presente trabajo aborda el problema de la clasificación automática de cinco especies de aves endémicas de la India mediante técnicas de Visión por Computadora y Deep Learning. Para ello, se diseñaron, entrenaron y evaluaron comparativamente tres arquitecturas de Redes Neuronales Convolucionales (CNN): un modelo construido desde cero (Custom CNN) y dos modelos basados en Transfer Learning empleando las bases pre-entrenadas de VGG16 y ResNet50. La metodología incluyó un pipeline unificado de Data Augmentation y una topología de cabezal clasificador compartido para

garantizar una métrica de comparación estandarizada. Los resultados experimentales demostraron que los modelos de Transfer Learning alcanzaron un rendimiento sobresaliente (VGG16 con 99.29 % y ResNet50 con 99.38 % de exactitud), mientras que la arquitectura Custom logró un sólido 90.49 %. El análisis crítico del desempeño reveló que el techo de aprendizaje del modelo Custom está condicionado por la sobre-regularización de la red, mientras que la eficacia de las redes pre-entrenadas confirma que no es necesario aplicar Fine-Tuning para la clasificación de clases visualmente disímiles.

Keywords: Redes Neuronales Convolucionales, Deep Learning, Transfer Learning, Data Augmentation, Visión por Computadora

1. Introducción

La clasificación automática de especies animales a partir de imágenes fotográficas constituye uno de los desafíos más relevantes en el campo de la Visión por Computadora. Específicamente, el reconocimiento de aves presenta dificultades intrínsecas debido a la similitud visual entre diferentes especies que comparten morfologías, patrones de color y texturas de plumaje, sumado a factores externos del entorno como variaciones de iluminación, diversidad de poses y encuadres asimétricos.

El presente trabajo tiene como objetivo principal diseñar, entrenar y comparar críticamente el rendimiento de tres modelos de Redes Neuronales Convolucionales (CNN) para la clasificación categórica [1] de cinco especies de aves endémicas de la India: *Indian Peacock* (Pavo Real), *Common Kingfisher* (Martín Pescador), *Hoopoe* (Abubilla), *Common Rosefinch* (Carmachuelo) y *Sarus Crane* (Grulla Sarus).

Para llevar a cabo este estudio, se evaluó el desempeño de una arquitectura diseñada e inicializada completamente desde cero (denominada en adelante como *CNN Custom*), contrastándola contra dos arquitecturas profundamente consolidadas en el estado del arte: VGG16 [2] y ResNet50 [3]. Estas dos últimas fueron implementadas mediante la técnica de *Transfer Learning* (Transferencia de Aprendizaje), empleando sus bases convolucionales previamente entrenadas con el masivo conjunto de datos de ImageNet. El propósito de esta comparativa trasciende la simple búsqueda de la mayor exactitud matemática (*Accuracy*); busca analizar de forma crítica las limitaciones arquitectónicas, el sobreajuste, y la relación costo-beneficio entre el diseño de redes propias frente al aprovechamiento de extracción de características de nivel profesional.

El conjunto de datos utilizado está compuesto por 7.500 imágenes en total, distribuidas equitativamente entre las cinco especies seleccionadas [4].. Para garantizar la validez estadística de los experimentos, los datos fueron segmentados destinando el 70 % de las imágenes para el proceso de entrenamiento, un 15 % para la fase de validación, y el 15 % restante (con un balance perfecto de 225 imágenes por clase) se operó como un conjunto de prueba (*Test*) aislado, asegurando así una evaluación final completamente imparcial.

2. Propuesta de Desarrollo

Para abordar el problema planteado, se diseñó una metodología basada en la comparativa de tres arquitecturas diferentes. Con el fin de aislar las variables y garantizar que la evaluación sea estrictamente justa, se estandarizó tanto la tubería de entrada de datos (*pipeline*) como la topología de clasificación final (cabezal) para todos los modelos.

2.1. Pipeline de Datos y Preprocesamiento

Debido a las limitaciones de memoria RAM inherentes al volumen del conjunto de datos, se implementaron flujos generadores de imágenes que leen y procesan los datos desde el disco en lotes (*batches*) de 32 imágenes de forma dinámica. Todas las fotografías fueron redimensionadas a un formato estándar de 224×224 píxeles.

Para mitigar el sobreajuste y enriquecer el conjunto de entrenamiento, se aplicaron técnicas de *Data Augmentation* en tiempo real: rotaciones aleatorias ($\pm 20^\circ$), desplazamientos horizontales y verticales (5 %), acercamientos (zoom del 10 %), deformación por cizallamiento (15 %), fluctuaciones de brillo (80 % a 120 %) y espejado horizontal. Se configuró el comportamiento `fill_mode='reflect'` para prevenir la aparición de bordes negros o artefactos visuales artificiales tras las transformaciones geométricas.

En cuanto al preprocesamiento matemático de los píxeles, la red *CNN Custom* utilizó un escalado lineal simple dividiendo sus valores por 255 (comprimiendo el rango a $[0, 1]$). En contraparte, las redes VGG16 y ResNet50 requirieron la aplicación de sus funciones de preprocesamiento nativas, las cuales invierten los canales de color (de RGB a BGR) y aplican un centrado en cero (*zero-centering*) basándose en los promedios estadísticos del dataset ImageNet original. Es imperativo destacar que los conjuntos de Validación y Prueba (*Test*) no fueron sometidos a *Data Augmentation*, preservando así su integridad evaluativa.

2.2. Cabezal Clasificador Compartido

Una decisión arquitectónica crítica fue la implementación de un cabezal clasificador idéntico acoplado a la salida de las tres bases convolucionales. El mismo consta de la siguiente estructura secuencial:

1. **Global Average Pooling 2D (GAP):** Reemplaza a las tradicionales capas *Flatten*, reduciendo drásticamente la cantidad de parámetros al promediar espacialmente cada mapa de características. Esta técnica minimiza el riesgo de sobreajuste y agiliza el cálculo computacional.
2. **Dense (256 neuronas, ReLU):** Capa totalmente conectada encargada de amalgamar las características visuales de alto nivel.
3. **Batch Normalization:** Estabiliza la varianza de las activaciones internas, permitiendo una convergencia más predecible.
4. **Dropout (50 %):** Regularización agresiva mediante el apagado aleatorio de conexiones para forzar a la red a no depender de características redundantes o individuales.
5. **Dense (5 neuronas, Softmax):** Capa de salida probabilística asignada a las cinco especies de aves.

2.3. Arquitecturas Convolucionales

1. CNN Custom: Se diseñó una red desde cero (Fig. 1) compuesta por cuatro bloques convolucionales sucesivos. Cada bloque inicia con una capa *Conv2D* (kernel 3×3 , padding "same") con un regularizador L2 agresivo ($\lambda = 0,005$) para penalizar la magnitud de los pesos. A la convolución le prosigue un *Batch Normalization*, una activación no lineal *ReLU*, una compresión espacial mediante *MaxPooling2D* (2×2) y un *Dropout* focalizado del 30 %. La progresión en el volumen de filtros a lo largo de los cuatro bloques asciende de $32 \rightarrow 64 \rightarrow 128 \rightarrow 256$, culminando en tensores de dimensión espacial 14×14 .

2. VGG16 (Transfer Learning): Se empleó el núcleo convolucional de VGG16, una arquitectura clásica caracterizada por la apilación secuencial profunda de convoluciones simples de 3×3 [2]. La base se inicializó con los pesos de ImageNet y se instanció con `trainable=False` (Feature Extraction puro), bloqueando la propagación de gradientes (*backpropagation*) en dichas capas durante el entrenamiento de este estudio.

3. ResNet50 (Transfer Learning): En contraste estructural con VGG16, ResNet50 emplea conexiones residuales (*skip connections*) que alivian la degradación del gradiente en topologías de gran profundidad (50 capas) [3]. Al igual que el modelo previo, sus características extraídas fueron congeladas y canalizadas exclusivamente hacia el cabezal clasificador superior.




Figura 1 – Arquitectura de la CNN Custom. Reducción espacial progresiva combinada con un aumento de la dimensionalidad de filtros de extracción.

2.4. Estrategia de Entrenamiento y Callbacks

El compendio de los tres modelos fue compilado utilizando el optimizador adaptativo *Adam* (tasa de aprendizaje de 0.001) y minimizando la función de pérdida *Categorical Crossentropy* [5]. Para garantizar un entrenamiento estable e ininterrumpido, se definieron mecanismos de control de flujo (*Callbacks*):

- **ReduceLROnPlateau:** Monitoriza la función de pérdida de validación (*val_loss*). Tras 2 épocas sin mejora aparente, reduce el *Learning Rate* multiplicándolo por 0.3, habilitando al optimizador a encontrar un mínimo más sutil.
- **EarlyStopping:** Otorga una tolerancia (*patience*) de 8 épocas frente al estancamiento de la validación. Transcurrido el límite, el entrenamiento se detiene y la red restaura la matriz de pesos que garantizó el menor error estadístico.
- **ModelCheckpoint y Persistencia:** Implementa una rutina de tolerancia a fallos por desconexión en el entorno Cloud (Colab), guardando los pesos actualizados directamente en la unidad de Google Drive del investigador.

3. Experimentos y Resultados

Para evaluar el grado de aprendizaje y generalización taxonómica, los tres modelos fueron sometidos al mismo conjunto de datos de Prueba (*Test set*) estrictamente aislado, compuesto por 1.125 imágenes (225 por clase). La Tabla 1 y la Fig. 2 condensan las métricas globales definitivas obtenidas.

Arquitectura	Test Accuracy (%)	Test Loss
CNN Custom	90.49	0.4153
VGG16 + TL	99.29	0.0282
ResNet50 + TL	99.38	0.0233

Cuadro 1 – Métricas globales comparativas de los tres modelos evaluados sobre el conjunto de Test.




Figura 2 – Comparativa del rendimiento (Accuracy y Loss) en el conjunto de Test para las tres arquitecturas evaluadas, evidenciando la superioridad del Transfer Learning.

3.1. Análisis de la CNN Custom y Curvas de Aprendizaje

A pesar de ser construida e inicializada desde cero con un volumen de datos acotado, la arquitectura Custom demostró una notable robustez estadística al superar la barrera del 90% de precisión general. El análisis de su progresión de aprendizaje a lo largo de las épocas (Fig. 3) revela un comportamiento clave para su diagnóstico.

Se observa que la exactitud de entrenamiento (*Train Accuracy*) alcanza un techo aproximado del $\sim 92\%$, mientras que la validación lo acompaña de cerca en un $\sim 91\%$, sin mostrar la clásica divergencia donde el *Training* se dispara al 99% y la validación cae. Según los fundamentos teóricos del aprendizaje automático [6], esta convergencia estrecha sugiere la presencia de una fuerte regularización paramétrica. Si bien inicialmente se hipotetizó que este comportamiento correspondía a un exceso de mecanismos restrictivos (sobre-regularización) que inducía un leve subajuste, pruebas posteriores de ablación reduciendo los umbrales de Dropout y L2 resultaron en una severa caída del rendimiento. Esto demuestra empíricamente que la alta carga




Figura 3 – Curvas de aprendizaje (Accuracy y Loss) de la CNN Custom. Nótese la estrecha convergencia entre las curvas de entrenamiento y validación, indicando ausencia de sobreajuste pero revelando un leve subajuste inducido.

restrictiva adoptada no era excesiva, sino el punto de equilibrio óptimo y estrictamente necesario para evitar que un modelo inicializado desde cero sobreajustara un conjunto de datos tan reducido.

Este fenómeno se refleja de manera transparente en la Matriz de Confusión del modelo (Fig. 4):

El modelo evidenció una confusión recurrente y focalizada entre la clase *Common Kingfisher* (Martín Pescador) y la clase *Indian Peacock* (Pavo Real), fallando sistemáticamente en 30 muestras. Visualmente, ambas especies comparten una prominente pigmentación iridiscente azul-verde. Dada la falta de profundidad paramétrica del modelo acoplada a la sobreregularización mencionada, la decisión de la red convergió predominantemente hacia la cromaticidad del plumaje en lugar de extraer bordes anatómicos discriminativos (como la geometría del pico).




Figura 4 – Matriz de Confusión de la CNN Custom evaluada sobre el conjunto de Test. Se destaca la alta concentración de falsos positivos en la intersección entre *Common Kingfisher* e *Indian Peacock*.

3.2. Análisis de VGG16 y ResNet50 (Transfer Learning)

En contraparte, las dos arquitecturas pre-entrenadas sortearon la barrera del color y la forma exhibiendo un desempeño virtualmente perfecto ($\sim 99.3\%$). Para auditar la fiabilidad de estos resultados se generaron las Curvas ROC (Fig. 5) de las predicciones multiclase.




Figura 5 – Curvas ROC multiclase generadas por el modelo VGG16. El perfil escuadrado y el Área Bajo la Curva (AUC) de 1.0 evidencian una separabilidad perfecta de las clases.

Las gráficas denotan perfiles geométricos rectangulares perfectos (Área Bajo la Curva - $AUC = 1,0$). Si bien estos elevados guarismos validan la abrumadora superioridad jerárquica de las características extraídas por ImageNet, un AUC de 1.0 en entornos biológicos obliga a dictaminar una hipótesis de sospecha sobre la estructura interna del *dataset*.

Una curva ROC .escuadrada"levanta fuertes indicios técnicos de *Data Leakage* (fuga de datos). Al separar las imágenes de forma aleatoria sin control de metadatos, las ráfagas fotográficas"(múltiples encuadres cuasi-identícos de la misma ave) fueron inevitablemente fraccionadas entre el set de Entrenamiento y Test. En consecuencia, la red no está generalizando

especies desconocidas de forma pura, sino recordando fotogramas casi exactos. Bajo mitigación de fuga de datos algorítmica mediante algoritmos como *pHash* (Perceptual Hashing), se postula que el rendimiento de estas redes convergería a un margen real y honesto del $\sim 96\%-97\%$.

4. Conclusiones

El presente trabajo permitió diseñar, entrenar y comparar críticamente tres modelos convolucionales orientados a la clasificación ornitológica, arrojando conclusiones fundamentales tanto a nivel arquitectónico como metodológico.

En primer lugar, el desempeño de la *CNN Custom* (90.49%) demostró que es viable alcanzar un estándar de alta precisión diseñando un modelo desde cero sobre un conjunto de datos acotado. Inicialmente se formuló la hipótesis de que el límite de precisión derivaba de una sobre-regularización. Sin embargo, pruebas empíricas posteriores reduciendo la penalización (Dropout de 0.3 a 0.15 y L2 de 0.005 a 0.0001) resultaron en una degradación del desempeño y reaparición de inestabilidad. Este hallazgo confirmó que el robusto esquema de regularización implementado era estrictamente necesario para controlar la varianza del modelo, estableciendo que el 90.49% representa un límite de generalización genuino para esta la arquitectura propuesta sin una transferencia de pesos. La asimetría residual en la clasificación de especies con pigmentación iridiscente similar (Por ejemplo, Kingfisher vs. Peacock) refleja las limitaciones intrínsecas de la extracción de características desde cero.

En segundo lugar, los modelos basados en *Transfer Learning* (VGG16 y ResNet50) exhibieron la superioridad innegable de los espacios de características pre-entrenados en ImageNet, alcanzando rendimientos superiores al 99.3% utilizando exclusivamente sus bases convolucionales congeladas (*Feature Extraction* puro).

Frente a esta abrumadora asertividad, la decisión metodológica del equipo de investigación fue **no implementar Fine-Tuning** sobre las capas convolucionales superiores. La justificación técnica detrás de esta exclusión deliberada se cimienta en tres factores de diseño:

- **Techo Estadístico:** Al alcanzar un 99.38% de exactitud con la base congelada, el margen de mejora matemática es indistinguible del ruido propio del entrenamiento.

- **Disimilitud de Clases:** Las cinco especies seleccionadas poseen diferencias visuales macroscópicas altamente contrastantes. Las características genéricas heredadas de ImageNet sobran para trazar los hiperplanos de separación. El *Fine-Tuning* está estrictamente indicado para tareas de clasificación de grano fino (*fine-grained classification*), donde las especies son visualmente idénticas a ojos inexpertos.
- **Riesgo de Catastrophic Forgetting:** Descongelar el bloque superior (*stage 5*) de ResNet50 implicaría habilitar el entrenamiento de millones de parámetros frente a un conjunto de apenas ~ 5.200 imágenes de entrenamiento. Esto introduciría un severo riesgo de sobreajuste y olvido catastrófico de los pesos genéricos originales, consumiendo recursos de hardware sin beneficios probabilísticos palpables.

Finalmente, el cuestionamiento interno de nuestro propio rendimiento perfecto (las Curvas ROC de AUC 1.0) reafirma la importancia crítica de auditar el origen y la pureza de los datos. La firme sospecha estadística de *Data Leakage* cruzado debido a ráfagas fotográficas en el conjunto original ratifica que, en Inteligencia Artificial, las métricas perfectas deben someterse invariablemente al escepticismo científico.

Como proyección a futuro, se propone escalar el algoritmo para clasificar las 25 especies completas del corpus biológico original. Es precisamente en dicho escenario de extremada complejidad inter-clase donde el *Fine-Tuning* parcial se convertirá en una necesidad arquitectónica ineludible.

Referencias

- [1] S. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*. Prentice Hall, 2nd ed., 2003.
- [2] K. Simonyan and A. Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition,” *arXiv preprint arXiv:1409.1556*, 2015.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- [4] Ichhadhari, “Indian birds dataset.” Kaggle Dataset, 2023. <https://www.kaggle.com/datasets/ichhadhari/indian-birds/>.
- [5] F. Chollet, “Keras: Deep Learning for Python,” *arXiv preprint arXiv:1409.1556*, 2015. <https://github.com/keras-team/keras>.
- [6] M. Ing Mario M. Figueroa de la Cruz, “Introducción a la inteligencia artificial: Apuntes de la cátedra.” Material de Cátedra, Universidad Tecnológica Nacional, 2024.
- [7] A. Basandrai, “25 Indian Bird Species with 226+ images each.” Kaggle Dataset, 2023. <https://www.kaggle.com/datasets/arjunbasandrai/25-indian-bird-species-with-226-images-each>.